

Toy models of súperposition.

Wellnote

Notebook

Toy Models of superposition

Feature sparse $\Leftrightarrow$ una feature q ocurre

muy poco frecuentemente. o sea: $P(\text{feature}) \ll 1$

En general si una feature es sparse el vector de activaciones tendrá muchos ceros.

Base privilegiada $\Leftrightarrow$ una hipótesis por la

cual las features se representan en el espacio de activaciones

En este caso:

- una feature active una sola neurona
- solamente se pueden representar m features si tengo m neuronas
- los $col(W)$ están alineados con los canónicos e_i

Superposición: Una feature se representa

como una dirección oblicua en el espacio de activaciones: $f = w_1 n_1 + w_2 n_2 + \dots + w_m n_m$

En este caso:

- con una feature se activan varias neuronas
- la capacidad de representarse puede ser $\rightarrow m$ ~~pero~~
- Interferencia entre los diferentes features (colabora si los features son sparse)

Neuronas poliseriánticas : ~~De~~ Con aquellos

q' e actúan con diferentes features.
En general los neuronas convénicas son
poliseriánticas porq' una ~~activa~~ ~~de~~
feature oblicua siempre lo va a activar.

Poliseriántica e me refiero a lo
neuronas. Esta e active con varios features
Superposición e me refiero a lo
feature por lo cual esta e active con muchos
neuronas.

Superposición e interferencia (Modelo lineal)

$$x' = W^T W x$$

$$W = \begin{bmatrix} w_1 & \dots & w_m \\ 1 & & 1 \end{bmatrix} \quad w_i \in \mathbb{R}^m$$

$$W^T W = [w_i^T w_j]_{\substack{i=1, \dots, m \\ j=1, \dots, m}}$$

Definimos : $e = x - x'$

de modo q'

$$\begin{aligned} \ell &= E\{e^T e\} = \text{tr}[E\{e e^T\}] = \\ &= E\{\text{tr}[e e^T]\} = \text{tr}[E\{e e^T\}] = \\ &= \text{tr}[E\{(x - x')(x - x')^T\}] = \text{tr}[E\{x x^T\} - E\{x x'^T\} - \\ &\quad - E\{x' x^T\} + E\{x' x'^T\}] = \text{tr}[\Sigma_{xx} - E\{x (W^T W x)^T\} - \\ &\quad - E\{W^T W x x^T\} + E\{W^T W x (W^T W x)^T\}] = \end{aligned}$$

$$= \text{tr}[\Sigma_{xx} - \Sigma_{xx} W^T W - W^T W \Sigma_{xx} + W^T W \Sigma_{xx} W^T W] =$$

$$= \text{tr}[\Sigma_{xx}] - \text{tr}[\Sigma_{xx} W^T W] - \text{tr}[W^T W \Sigma_{xx}] + \text{tr}[W^T W \Sigma_{xx} W^T W]$$

Por ser las features x_i independiente entre sí

$$\text{tr}[\Sigma_{xx}] = D_x \quad \text{y por conmutación de tr}$$

$$J = D_x - 2 \text{tr}[D_x W^T W] + \text{tr}[D_x (W^T W)^2]$$

$$D_x = [d_{ii}] \quad W^T W = [a_{ij}] = [w_i^T w_j]$$

$$\text{tr}[D_x W^T W] = \sum_i d_{ii} a_{ii}$$

$$\text{tr}[D_x (W^T W)^2] = \sum_i \sum_j d_{ii} a_{ij}^2$$

$$J = \sum_i d_{ii} - 2 \sum_i d_{ii} a_{ii} + \sum_i \sum_j d_{ii} a_{ij}^2$$

$$= \sum_i d_{ii} - 2 \sum_i d_{ii} a_{ii} + \sum_i \sum_{j \neq i} d_{ii} a_{ij}^2 + \sum_i d_{ii} a_{ii}^2 =$$

$$= \sum_i d_{ii} (1 - 2a_{ii} + a_{ii}^2) + \sum_i \sum_{j \neq i} d_{ii} a_{ij}^2 =$$

$$= \sum_i d_{ii} (1 - a_{ii})^2 + \sum_i \sum_{j \neq i} d_{ij} a_{ij}^2$$

$$d_{ii} = E\{x_i^2\} = \sigma_i^2$$

$$a_{ij} = w_i^T w_j$$

$$l_{ii} = \|w_i\|^2$$

Replayando:

minimizar
etc. (una vez por
mayor I_i)

hacer o otro
~~pero~~

$$L = \sum_i I_i (1 - \|w_i\|^2)^2 + \sum_i \sum_{j \neq i} I_i I_j (w_i^T w_j)^2$$

Superposición e interferencia (Modelo Relu)

$$L = E \{ e^T I e \} = \int_x I(x - \text{Relu}(w^T w x + b))^2 p(x) dx$$

donde $I = \text{diag}(\sqrt{I_1}, \sqrt{I_2}, \dots, \sqrt{I_n})$

cada vector x puede tener k componentes q no son 0. Si s es la probabilidad de q en componente cualquiera valga 0, la distribución de componentes q son 0 o no 0 será multinomial

Si llamamos n_a a la cantidad de features activos (distintos de 0), la pérdida total será

$$L = P(n_a=0) L_0 + \dots + P(n_a=k) L_k + \dots + P(n_a=n) L_n$$

Por ser una multinomial:

$$P(n_a=k) = \binom{n}{k} (1-s)^k s^{n-k}$$

Entonces la pérdida total será

$$L = P(n_a=0) L_0 + \dots + P(n_a=k) L_k + \dots + P(n_a=n) L_n$$

Si hacemos $S \rightarrow 1$ los vectores serán muy sparse (habrá muchos componentes q' valgan 0) si esto ocurre podemos despreocupar los penúltimos por valores superiores ya q' los $P(u_a = k)$ serán muy bajos (ya q' hay pocas features activas) $\therefore$

$$L \approx P(u_a = 0)L_0 + P(u_a = 1)L_1$$

Lo q' esto dice es q' vamos a poder almacenar n features en un espacio de dimensión m . Siempre y cuando los features tengan de 0 a uno.

Ojo! Si k es grande L_k es cada vez más grande pero como $P(u_a = k)$ es cada vez más chico no tendrá influencia siempre q' $S \rightarrow 1$.

solu la función de costo (conexión)

$$L = E\{e^T I e\} \quad \text{donde} \quad e = x - x'$$

$$I = \text{diag}(I_i, i=1, m)$$

en el caso $x' = v^T u x$ usando la propiedad.

$$e^T I e = \text{tr}(e I e^T)$$

Ade más asumimos q' los features son independientes $\therefore P(x_1 \dots x_n) = \prod_i P(x_i)$

$$\text{en el caso discreto} \quad L = \sum_x e^T I e = \sum_x \sum_i I_i (x - x_i)^2$$

Comparación entre ambos modelos

$$L = \sum_i I_i (1 - \|w_i\|^2)^2 + \sum_{i \neq j} I_j (w_j^T w_i)^2$$

$$L_1 = \sum_i I_i (1 - \text{Relu}(\|w_i\|^2 + b_i))^2 + \sum_{i \neq j} I_j \text{Relu}(w_j^T w_i + b_j)^2$$

La diferencia entre ambos es q' la Relu hace q' las interferencias negativas o las interferencias en los q' b_j hace q' $w_j^T w_i$ no negativo
El término tiene costo cond este cond de L_1 corresponde a $x_i = 1$

Resumiendo:

- caso lineal: L se minimiza si no hay interferencia. $\therefore$ lo q' hace la red es discriminar las features más importantes (las m más importantes) y el resto no las considera

- caso Relu: Si $S \rightarrow 1$ solo los términos L_0 y L_1 afectarían la L ya q' aunque L_1 sea grande $P(u_0 = u)$ es muy chico entonces se desprecia.
y ~~potencia~~ se agrega el hecho de q' si $w_i^T w_j + b_j$ es negativo el término vale 0. por lo tanto se podrán representar 2 features en la misma dirección si forman 180° . o sea q' habrá preferencia por las interferencias negativas
En consecuencia no aquellos features q' tienen interferencia negativa con los q' ya están pueden ser agregados. Ojo: $S \rightarrow 1$ es lo hip. fundamental.

